

Пояснительная записка к итоговому проекту

Тема: Нормализация данных о доставках и построение аналитических витрин с помощью Airflow и PySpark.

Проект реализован на базе микросервисной архитектуры с использованием Docker Compose. Система состоит из 4-х контейнеров (PostgreSQL, Airflow Webserver, Airflow Scheduler, pgAdmin), объединенных в общую сеть. Это позволило изолировать процессы хранения и обработки данных (PySpark), обеспечив масштабируемость и отказоустойчивость системы.

1. Описание нормализованной схемы (3NF)

Для устранения избыточности и обеспечения целостности данных исходный денормализованный набор данных был разделен на следующие сущности:

1. **users:** информация о клиентах (ID, телефон).
2. **stores:** данные о магазинах (ID, адрес).
3. **orders:** сведения о заказах (ID, ссылка на пользователя, ссылка на магазин, адрес доставки, время создания).
4. **order_items:** состав заказов (ID заказа, ID товара, название, категория, количество и цена).
Первичный ключ: (order_id, item_id).

Обоснование выбора 3NF:

- **Устранение дублирования:** Данные пользователя и магазина (телефон, адрес магазина) хранятся в единственном экземпляре.
- **Целостность:** Использование внешних ключей (Foreign Keys) гарантирует, что нельзя создать заказ на несуществующего пользователя.
- **Гибкость:** Категории товаров вынесены в таблицу позиций, что позволяет детализировать продажи по категориям без повторения заголовков заказов.

2. DDL-скрипты создания таблиц

```
CREATE TABLE IF NOT EXISTS users (  
    user_id INTEGER PRIMARY KEY,  
    user_phone TEXT UNIQUE  
);
```

```
CREATE TABLE IF NOT EXISTS stores (  
    store_id INTEGER PRIMARY KEY,  
    store_address TEXT  
);
```

```
CREATE TABLE IF NOT EXISTS orders (  
    order_id INTEGER PRIMARY KEY,  
    user_id INTEGER REFERENCES users(user_id),  
    store_id INTEGER REFERENCES stores(store_id)
```

```

        created_at TIMESTAMP
    );

CREATE TABLE IF NOT EXISTS order_items (
    order_id INTEGER REFERENCES orders(order_id),
    item_id INTEGER,
    item_title TEXT,
    item_category TEXT,
    item_quantity INTEGER,
    item_price DECIMAL,
    PRIMARY KEY (order_id, item_id)
);

```

3. Описание ETL-процесса в Airflow

Процесс разделен на два независимых (идемпотентных) DAG-файла:

1. **DAG 01 (Normalization):** Читает Parquet-файлы с помощью Pandas, очищает таблицы в PostgreSQL и загружает данные, распределяя их по нормализованным таблицам.
2. **DAG 02 (Analytics):** С помощью **PySpark** подключается к PostgreSQL через JDBC, выполняет агрегацию данных (расчет выручки по категориям и статистику по магазинам) и записывает результаты в таблицы витрин (vitrine_orders, vitrine_items).

4. Результаты (Витрина категорий)

На основе PySpark-расчетов получены следующие данные (Топ-3 категорий по выручке):

1. **Мясо:** ~2.33 млрд руб.
2. **Овощи:** ~2.15 млрд руб.
3. **Фрукты:** ~1.63 млрд руб.

5. Структура

```

final_project/
├── docker-compose.yml
├── Dockerfile
├── dags/
│   ├── 01_normalize_data.py
│   └── 02_vitrines.py
├── sql/
│   └── postgresql-42.6.0.jar
└── team_11/ (parquet файлы)

```